Deep Learning

Contents

Introduction 1

Part I Course Notes 3

Chapter 1 Neural Networks and Deep Learning 5

1.1 Introduction to Deep Learning 5

1.2 Neural Networks Basics 5

1.2.1 Binary Classification 5

1.2.2 Logistic Regression 6

1.2.3 Gradient Descent 7

1.2.4 Vectorization 8

Part II Projects 11

Chapter 2 短章名 13

2.1 长度正常的节名 13

2.2 短节名 14

习题 14

Appendix A 杂项 $a+b$ 17

A.1 文字测试 17

A.2 测试: $B_n(X)$ 18

A.2.1 一张表格 18

Bibliography 19

List of Figures 21

List of Tables 23

Keyword Index **25**

Introduction

本文档为 `Deeplearning.ai` 开设的深度学习系列课程的个人笔记。

By Imiloin

Github profile

Part I

Course Notes

Chapter 1 Neural Networks and Deep Learning

1.1 Introduction to Deep Learning

机器学习本质上就是训练模型来完成**从输入到输出 ($X \to Y$) 的映射**。例如, 给定一张猫的照片, 机器学习模型可以输出 “这是一只猫” 的结论。

深度学习有 3 大要点:

- Data
- Computation
- Algorithms

Data 可以分为 Structured Data 和 Unstructured Data。Structured Data 是指有固定格式的数据, 例如表格、数据库等。Unstructured Data 是指没有固定格式的数据, 例如图片、音频、视频等。

Computation 是指计算机的计算能力, 例如 CPU、GPU、TPU 等。

Algorithms 是指算法, 例如 Logistic Regression、SVM、Neural Networks 等。

1.2 Neural Networks Basics

1.2.1 Binary Classification

表 1.1 是本章用到的符号说明。

Table 1.1: 表格标题

	Notation	Description	Meaning
Sizes	m	value	样本容量
	n_x	value	单个样本的特征数（输入）
	n_y	value	单个样本的标签数（输出）
	$n_h^{[l]}$		
	L		
Objects	$x^{(i)} \in \mathbb{R}^{n_x}$	vector	第 i 个样本数据
	$X \in \mathbb{R}^{n_x \times m}$	matrix	输入矩阵
	$a^{(i)}/y^{(i)} \in \mathbb{R}^{n_y}$	vector	第 i 个样本的标签
	$Y \in \mathbb{R}^{n_y \times m}$	matrix	标签矩阵（$n_y = 1$ 时退化为行向量 y）
	$\hat{y}^{(i)} \in \mathbb{R}^{n_y}$	vector	第 i 个样本的标签预测值向量
	$\hat{Y} \in \mathbb{R}^{n_y \times m}$	matrix	标签预测值矩阵（$n_y = 1$ 时退化为行向量 $\hat{y}$）
	$W \in \mathbb{R}^{n_x \times n_y}$	matrix	权重矩阵（$n_y = 1$ 时退化为列向量 w）
	$b \in \mathbb{R}^{n_y}$	vector	标签偏置值向量
	$W^{[l]}$		
	$b^{[l]}$		
Other	$J(x, W, b, y)$ or $J(\hat{y}, y)$	function	代价函数
	dvar	differential	代价函数对变量 var 的微分，即 $\mathrm{d}J/\mathrm{dvar}$

* 通常情况下 (i) 表示第 i 个样本，而 $[l]$ 表示第 l 层。

1.2.2 Logistic Regression

对于**二元分类模型，$n_y = 1$**，相关公式如下：

$$\hat{y}^{(i)} = \sigma(w^{\mathrm{T}} x^{(i)} + b) \tag{1.2–1}$$

其中 sigmoid 函数 $\sigma(z)$ 定义为：

$$\sigma(z) = \frac{1}{1 + \mathrm{e}^{-z}} \tag{1.2–2}$$

该函数可以把实数域 $\mathbb{R}$ 映射到区间 $(0, 1)$，如图 1.1 所示。而 $z = w^{\mathrm{T}} x + b$ 为线性函数，w 为权重（weight），b 为偏置（bias）。

对某一个样本而言，Loss function（误差函数）定义为:

$$L(\hat{y}^{(i)}, y^{(i)}) = -[y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})] \tag{1.2–3}$$

该函数与方差类似，当样本的误差越大，Loss function 的值越大，如图 1.2 所示。

对整个模型而言，Cost function（代价函数）定义为:

$$J(w, b) = \frac{1}{m} \sum_{i=1}^{m} L(\hat{y}^{(i)}, y^{(i)}) = -\frac{1}{m} \sum_{i=1}^{m} [y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})] \tag{1.2–4}$$

相当于误差函数的平均值。

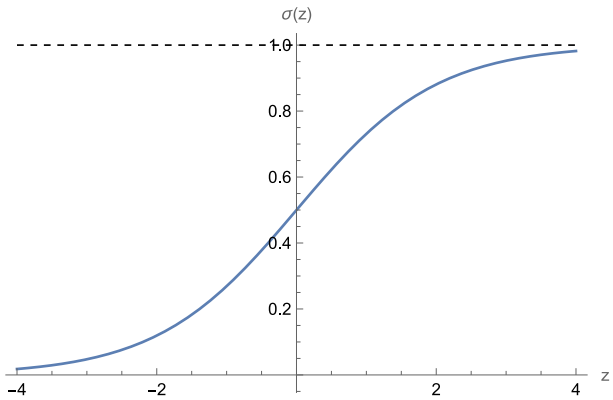

Figure 1.1: Sigmoid 函数，关于点 (0, 0.5) 对称

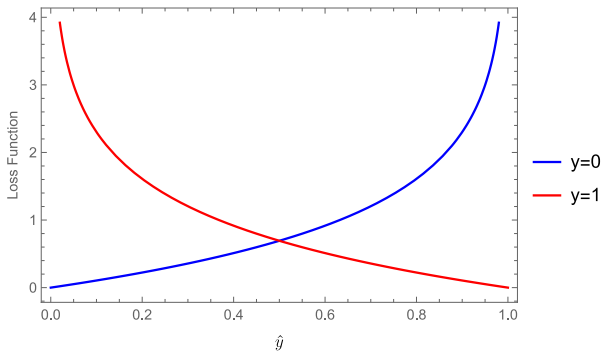

Figure 1.2: Loss Function 误差函数

1.2.3 Gradient Descent

训练过程使用梯度下降（Gradient Descent）算法，即：

$$\mathrm{var} = \mathrm{var} - \alpha \frac{\mathrm{d}J}{\mathrm{dvar}} \tag{1.2–5}$$

其中 var 为一个需要调整的参数，α 为学习率（Learning Rate）。对于 Logistic Regression，梯度下降算法的表达式为：

$$\begin{aligned} w &:= w - \alpha \frac{\mathrm{d}J}{\mathrm{d}w} \\ b &:= b - \alpha \frac{\mathrm{d}J}{\mathrm{d}b} \end{aligned} \tag{1.2–6}$$

其中 := 表示赋值，通过不断更新 w, b 的值使 J 尽可能小。下面介绍具体实现

对于一个样本，有

$$\begin{aligned} z &= w^{\mathrm{T}} x^{(i)} + b \\ \hat{y}^{(i)} &= \sigma(z) \\ L(\hat{y}^{(i)}, y^{(i)}) &= -[y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})] \end{aligned} \tag{1.2–7}$$

进行求导（x, y 均为常量），有

$$\begin{aligned}\frac{\mathrm{d}L}{\mathrm{d}\hat{y}^{(i)}} &= -\frac{y^{(i)}}{\hat{y}^{(i)}} + \frac{1-y^{(i)}}{1-\hat{y}^{(i)}} \\ \frac{\mathrm{d}\hat{y}^{(i)}}{\mathrm{d}z} &= \frac{\mathrm{e}^{-z}}{(1+\mathrm{e}^{-z})^2} = \frac{1}{1+\mathrm{e}^{-z}}(1-\frac{1}{1+\mathrm{e}^{-z}}) = \hat{y}^{(i)}(1-\hat{y}^{(i)})\end{aligned} \tag{1.2–8}$$

用链式法则，有

$$\frac{\mathrm{d}L}{\mathrm{d}z} = \frac{\mathrm{d}L}{\mathrm{d}\hat{y}^{(i)}}\frac{\mathrm{d}\hat{y}^{(i)}}{\mathrm{d}z} = (-\frac{y^{(i)}}{\hat{y}^{(i)}} + \frac{1-y^{(i)}}{1-\hat{y}^{(i)}})\hat{y}^{(i)}(1-\hat{y}^{(i)}) = \hat{y}^{(i)} - y^{(i)} \tag{1.2–9}$$

进而有

$$\begin{aligned}\frac{\mathrm{d}L}{\mathrm{d}w_j} &= \frac{\mathrm{d}L}{\mathrm{d}z}\frac{\mathrm{d}z}{\mathrm{d}w_j} = x_j^{(i)}(\hat{y}^{(i)} - y^{(i)}) \quad (1 \leqslant j \leqslant n_x) \\ \frac{\mathrm{d}L}{\mathrm{d}b} &= \frac{\mathrm{d}L}{\mathrm{d}z}\frac{\mathrm{d}z}{\mathrm{d}b} = \hat{y}^{(i)} - y^{(i)}\end{aligned} \tag{1.2–10}$$

对于整个训练集，在一个循环中我们对每一个样本都进行一次梯度下降，并对所有样本的梯度进行平均，有

$$\begin{aligned}\frac{\mathrm{d}J}{\mathrm{d}w_j} &= \frac{1}{m}\sum_{i=1}^{m}\frac{\mathrm{d}L}{\mathrm{d}w_j} = \frac{1}{m}\sum_{i=1}^{m}x_j^{(i)}(\hat{y}^{(i)} - y^{(i)}) \quad (1 \leqslant j \leqslant n_x) \\ \frac{\mathrm{d}J}{\mathrm{d}b} &= \frac{1}{m}\sum_{i=1}^{m}\frac{\mathrm{d}L}{\mathrm{d}b} = \frac{1}{m}\sum_{i=1}^{m}(\hat{y}^{(i)} - y^{(i)})\end{aligned} \tag{1.2–11}$$

得到梯度的平均值后，再进行参数更新，即

$$\begin{aligned}w_j &:= w_j - \alpha\frac{\mathrm{d}J}{\mathrm{d}w} \quad (1 \leqslant j \leqslant n_x) \\ b &:= b - \alpha\frac{\mathrm{d}J}{\mathrm{d}b}\end{aligned} \tag{1.2–12}$$

这样就完成了一轮梯度下降的循环。重复多次梯度下降，直到 J 收敛或达到最大迭代次数，就得到了最终的 w, b。

1.2.4 Vectorization

一个重要的原则是，在训练过程中要避免使用循环，而是使用向量化的方法。要完成下面的矩阵操作，

$$Z = \begin{bmatrix} z^{(1)} & z^{(2)} & \dots & z^{(m)} \end{bmatrix} = w^{\mathrm{T}}X + \begin{bmatrix} b & b & \dots & b \end{bmatrix} \tag{1.2–13}$$

可以使用下面的代码

```
import numpy as np
# define X, Y, w, b
Z = np.dot(w.T, X) + b
```

同理，要实现

$$\begin{aligned}\frac{\mathrm{d}J}{\mathrm{d}w_j} &= \frac{1}{m}\sum_{i=1}^{m}\frac{\mathrm{d}L}{\mathrm{d}w_j} = \frac{1}{m}\sum_{i=1}^{m}x_j^{(i)}(\hat{y}^{(i)} - y^{(i)}) \quad (1 \leqslant j \leqslant n_x) \\ \frac{\mathrm{d}J}{\mathrm{d}b} &= \frac{1}{m}\sum_{i=1}^{m}\frac{\mathrm{d}L}{\mathrm{d}b} = \frac{1}{m}\sum_{i=1}^{m}(\hat{y}^{(i)} - y^{(i)})\end{aligned} \tag{1.2–14}$$

可以继续使用下面的代码

```
def sigmoid(x):
    s = 1 / (1 + np.exp(-x))
    return s


A = sigmoid(Z)
dZ = A - Y
dw = np.dot(X, dZ.T) / m
# sum along the column
db = np.sum(dZ, axis=1) / m
# sum will get a row vector regardless of the axis parameter, so we need to reshape it
db = db.reshape(ny, 1)
```

`np.sum()` 函数的 `axis` 参数表示沿着哪个维度进行求和，`axis=0` 表示沿着列求和，`axis=1` 表示沿着行求和。

在 `numpy` 中，矩阵的维度扩充与 `matlab` 类似，可以自动扩充，也可以使用 `reshape` 函数进行扩充。

矩阵在保存时，使用了两重方括号，例如 `[[1, 2], [3, 4]]`，而向量仅有一重方括号，例如 `[1, 2, 3, 4]`。要把向量转换为矩阵，可以使用 `reshape()` 函数，例如

```
A = np.array([1, 2, 3, 4])
print(A)
A = A.reshape(1, 4)
print(A)
```

输出结果为

```
[1 2 3 4]
[[1 2 3 4]]
```

`reshape()` 是一个 O(1) 的操作，因此不会影响程序的运行效率。

Part II

Projects

Chapter 2 这是一个充分长的章名，强势占用三行没商量.

如果章名过长, 可以在目录和天眉以另外设置的短章名显示, 方式和 LaTeX 的标准文档类 book 相同.

2.1 长度正常的节名

复数 τ 的虚部记为 $\mathrm{Im}(\tau)$. 自然对数记为 $\log$.

约定 2.1.1 本节记 Poincaré 上半平面为

$$\mathcal{H} := \{\tau \in \mathbb{C} : \mathrm{Im}(\tau) > 0\}.$$

按例记 $q := e^{2\pi i\tau}$. **Dedekind η 函数**定义为无穷乘积

$$\eta(\tau) := e^{2\pi i\tau/24} \prod_{n=1}^{\infty} (1 - q^n), \quad \tau \in \mathcal{H}.$$

由分析学常识易见此无穷乘积绝对收敛. 进一步，η 在 $\mathcal{H}$ 上全纯无零点; 此外 η 的对数导数为

$$\frac{\mathrm{d}}{\mathrm{d}\tau} \log \eta(\tau) := \frac{\eta'(\tau)}{\eta(\tau)} = \frac{\pi i}{12} - 2\pi i \sum_{n=1}^{\infty} \frac{nq^n}{1 - q^n}.$$

例 2.1.2 在右半复平面上定义 $\sqrt{z} := \exp(\log|z| + i\arg(z))$, 其中幅角取 $\arg(z) \in \left[-\frac{\pi}{2}, \frac{\pi}{2}\right]$. 则

$$\eta\left(\frac{-1}{\tau}\right) = \sqrt{-i\tau} \cdot \eta(\tau), \quad \tau \in \mathcal{H}.$$

证明 应用 Eisenstein 级数 E_2 的性质, 将对数导数 $\frac{\mathrm{d}}{\mathrm{d}\tau}\log\eta(\tau)$ 整理为

$$\frac{\pi i}{12}-2\pi i\sum_{d\geq 1}\frac{dq^d}{1-q^d}=\frac{\pi i}{12}-2\pi i\sum_{d\geq 1}\sum_{k\geq 1}dq^{dk}$$
$$\overset{n:=dk}{=}\frac{\pi i}{12}-2\pi i\sum_{n\geq 1}\sigma_1(n)q^n=\frac{\pi i}{12}\cdot E_2(\tau),$$

若改为对 $\tau\mapsto\eta(\frac{-1}{\tau})$ 求对数导数, 再应用 E_2 的函数方程, 产物则是

$$\tau^{-2}\cdot\frac{\pi i}{12}\cdot E_2\left(\frac{-1}{\tau}\right)=\frac{\pi i}{12}\left(E_2(\tau)+\frac{12}{2\pi i\tau}\right).$$

对 $\sqrt{-i\tau}$ 求对数导数给出 $\frac{1}{2}\frac{\mathrm{d}}{\mathrm{d}\tau}\log(-i\tau)=\dfrac{1}{2\tau}=\dfrac{\pi i}{12}\cdot\dfrac{12}{2\pi i\tau}$. 与上式对比即见

$$\begin{aligned}\frac{\mathrm{d}}{\mathrm{d}\tau}\log\eta\left(\frac{-1}{\tau}\right)&=\frac{\mathrm{d}}{\mathrm{d}\tau}\log\sqrt{-i\tau}+\frac{\mathrm{d}}{\mathrm{d}\tau}\log\eta(\tau)\\&=\frac{\mathrm{d}}{\mathrm{d}\tau}\log\left(\sqrt{-i\tau}\cdot\eta(\tau)\right).\end{aligned}$$

故存在 $c\in\mathbb{C}^\times$ 使得 $\eta\left(\frac{-1}{\tau}\right)=c\sqrt{-i\tau}\cdot\eta(\tau)$; 因为 $\eta(i)\neq 0$, 代入 $\tau=i$ 可知 $c=1$. □

著名的 Euler 五边形数定理写作

$$\sum_{n\in\mathbb{Z}}(-1)^n q^{(3n^2+n)/2}=\prod_{n\geq 1}(1-q^n); \tag{2.1–1}$$

留意到 $3n^2+n\equiv 0 \pmod 2$ 恒成立. 将 $\frac{3n^2+n}{2}=\frac{(6n+1)^2-1}{24}$ 代入 (2.1–1), 即可导出 η 的 Fourier 展开

$$\eta(\tau)=\sum_{n\in\mathbb{Z}}(-1)^n q^{\frac{1}{24}\cdot(6n+1)^2},\quad q^{1/24}:=e^{2\pi i\tau/24}.$$

2.2 四十男儿学干谒，朝游江淮暮吴越。漫将衣食累朱门，讵有文章动金阙。倦游屡岁赋归欤，故人相值还唏嘘。劝我莫作千里客，留我共读三冬书。忆别吴阊一年久，为我糟床压春酒。入座争迎作赋才，当筵更觅弹筝手。酒酣慷慨唤奈何，风光一往如流波。女坟湖北莺犹少，短簿祠南雨正多。君家奇书一千轴，锦袱牙签光历碌。愿随潘左伴青缃，羞与金张斗华毂。嗟余短鬓日苍浪，太息忧来未可忘。鼓挝马槊差亦得，若问读书非我长。

原诗作者: [清] 陈维崧.

不鼓励使用过长的节名. 同样地, 可以在目录和天眉以另外设置的短节名显示, 方式和 LaTeX 的标准文档类 book 相同.

图片取自 Wikimedia Commons, 经过适当加工.

习题

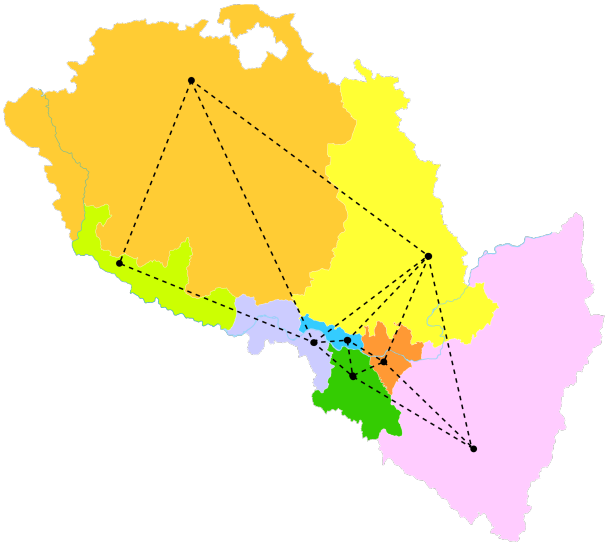

Figure 2.1: 兰州市地图

1. 造访兰州. 提示 低碳出行, 请乘坐火车.

2. 造访祁连山.

这是一篇关于 LaTeX 的参考文献 [1]。

Appendix A 杂项 $a+b$

按惯例, 附录以字母编号.

A.1 文字测试

龚自珍, **乙亥杂诗**:

1. 其一

掌故罗胸是国恩，小胥脱腕万言存。
他年金匮如收采，来叩空山夜雨门。

2. 其二

九州生气恃风雷，万马齐喑究可哀。
我劝天公重抖擞，不拘一格降人才。

3. 其三

吟罢江山气不灵，万千种话一灯青。
忽然搁笔无言说，重礼天台七卷经。

定义–定理 A.1.1 (龚自珍) 《己卯京师作杂诗二首》:

文格渐卑庸福近, 不知庸福究何如?
常州庄四能怜我, 劝我狂删乙丙书。

交叉参照: 引理 **??**.

A.2 测试: $B_n(X)$

首先介绍 Bernoulli 多项式. 多项式变元记为 X.

定义–命题 A.2.1 Bernoulli 多项式 $B_n(X) \in \mathbb{Q}[X]$ 由生成函数

$$\frac{te^{tX}}{e^t-1} = \sum_{n\geq 0} B_n(X)\cdot\frac{t^n}{n!} \in \mathbb{Q}[X][\![t]\!] \tag{A.2–1}$$

确定. 称 $B_n := B_n(0)$ 为第 n 个 **Bernoulli 数**.

A.2.1 一张表格

以下来测试表格.

n	0	1	2	4	6	8	10	12
B_n	1	$-\frac{1}{2}$	$\frac{1}{6}$	$-\frac{1}{30}$	$\frac{1}{42}$	$-\frac{1}{30}$	$\frac{5}{66}$	$\frac{-691}{2730}$

Table A.1: 前几个 Bernoulli 常数.

交叉参照: 练习 **??**.

猜想 A.2.2 (周恩来, 1917) 大江歌罢掉头东，邃密群科济世穷。面壁十年图破壁，难酬蹈海亦英雄。

假设 A.2.3 Riemann ζ 函数的非平凡零点全在 $\mathrm{Re}(s) = \frac{1}{2}$ 上.

引用测试: [**Oxl11**, **ZG**]

Bibliography

[1] Leslie Lamport. *LaTeX: A Document Preparation System*. Addison-Wesley, 1994 (引用于 p. 16).

List of Figures

1.1 Sigmoid 函数，关于点 (0, 0.5) 对称 7
1.2 Loss Function 误差函数 7

2.1 兰州市地图 15

List of Tables

1.1 表格标题 6

A.1 前几个 Bernoulli 常数. 18

Keyword Index

中文术语按汉语拼音排序.

B
Bernoulli 多项式 (Bernoulli polynomials), 16

D
Dedeking η 函数, 11

G
龚自珍, 15

W
五边形数定理 (pentagonal number theorem), 12

Z
周恩来, 16